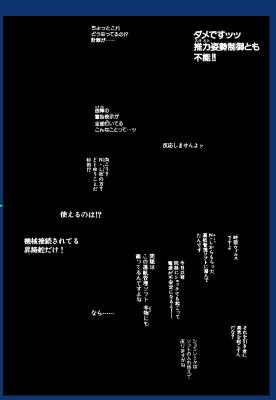


Pedro H. B. de Almeida Estudante Nina S. T. Hirata Orientadora

O PROBLEMA: SEGMENTAÇÃO DE IMAGENS

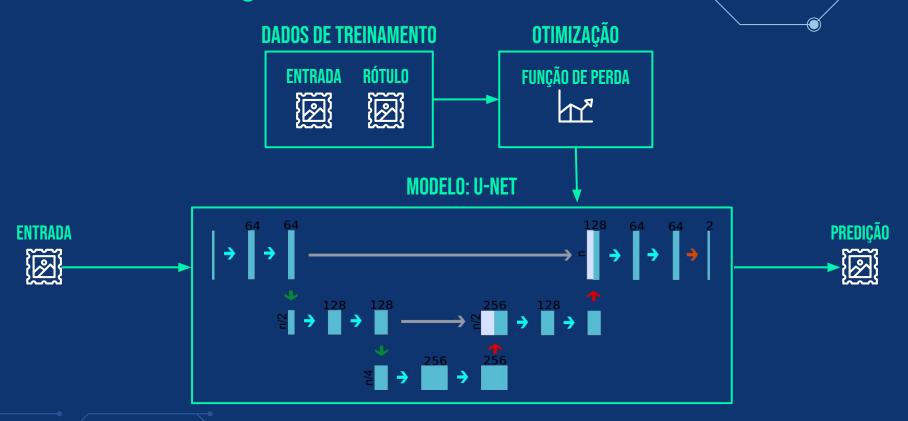




ENTRADA

ALVO

ARCABOUÇO DO APRENDIZADO SUPERVISIONADO



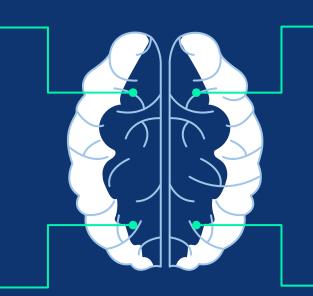
DESAFIOS

CAPACIDADE DA REDE

Overfit vs underfit;

VARIABILIDADE DE ESCRITAS

Os estilos dos caracteres podem variar muito em um mesmo mangá;



QUANTIDADE DE HIPERPARÂMETROS

Grande quantidade de hiperparâmetros para serem testados;

DESBALANCEAMENTO DE CLASSES

Aproximadamente 90% dos píxels são negativos.

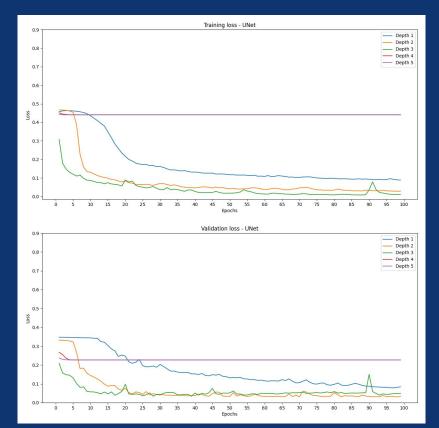
OBJETIVOS

- Treinar os modelos em contextos com poucos exemplos (<10);
- Ajustar hiperparâmetros para diminuir falsos positivos e falsos negativos;
- Investigar os impactos de cada hiperparâmetro.



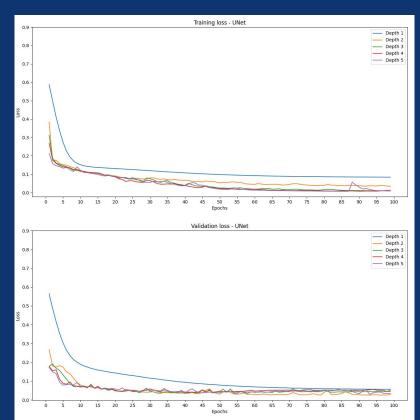
EXPERIMENTO 1: CAPACIDADE

	ACURÁCIA	PRECISÃO	RECALL
PROF. 1	0,988	0,433	0,193
PROF. 2	0,994	0,735	0,670
PROF. 3	0,993	0,753	0,578
PROF. 4	0,989	-	0,000
PROF. 5	0,989	-	0,000



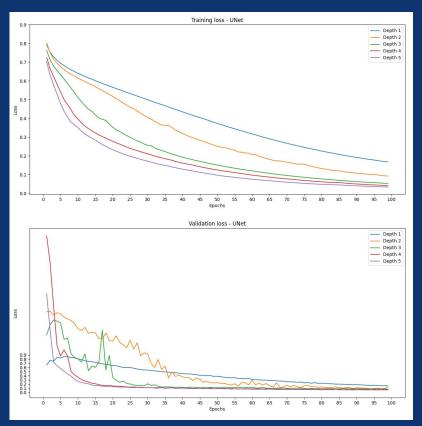
EXPERIMENTO 2: NORM. DE ENTRADA

	ACURÁCIA	PRECISÃO	RECALL
PROF. 1	0,989	0,484	0,020
PROF. 2	0,993	0,826	0,516
PROF. 3	0,990	0,932	0,090
PROF. 4	0,995	0,834	0,689
PROF. 5	0,997	0,941	0,763



EXPERIMENTO 3: NORM. DE BATCH

	ACURÁCIA	PRECISÃO	RECALL
PROF. 1	0,988	0,456	0,475
PROF. 2	0,996	0,843	0,747
PROF. 3	0,997	0,864	0,857
PROF. 4	0,998	0,917	0,869
PROF. 5	0,997	0,912	0,797



EXPERIMENTO 4: FUNÇÕES DE PERDA

	ACURÁCIA	PRECISÃO	RECALL
GDL	0,997	0,880	0,823
WCE	WCE 0,991		0,215
CE	0,990	0,932	0,090
FL	FL 0,994		0,635

EXPERIMENTO 5: AVALIAÇÃO CRUZADA

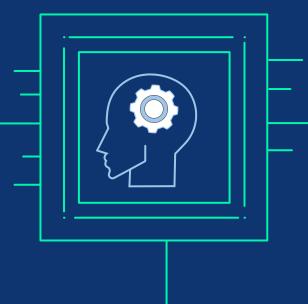
TREINO	TESTE	ACURÁCIA	PRECISÃO	RECALL
A	Α	0,996	0,857	0,813
A	В	0,998	0,735	0,821
Α	C	0,996	0,677	0,956
A	D	0,995	0,700	0,815

TREINO	TESTE	ACURÁCIA	PRECISÃO	RECALL
C	Α	0,992	0,848	0,513
C	В	0,998	0,867	0,702
C	C	0,998	0,890	0,943
C	D	0,995	0,805	0,593

В	A	0,992	0,772	0,577
В	В	0,998	0,839	0,853
В	C	0,997	0,814	0,883
В	D	0,994	0,738	0,660

D	A	0,994	0,867	0,639
D	В	0,998	0,799	0,676
D	C	0,996	0,745	0,810
D	D	0,996	0,844	0,786

CONCLUSÕES



- Não existe estudo parecido com este;
- 10 páginas são suficientes;
- U-Net de profundidade 3 generaliza bem neste problema;
- Normalização de entrada traz benefícios e não prejudica tanto o tempo decorrido;
- A função de perda GDL contribui para uma melhor performance;
- Uma rede treinada em um título funciona bem em outro título;

OBRIGADO!

Pedro H. B. de Almeida Estudante

Nina S. T. Hirata
Orientadora

Este projeto foi financiado pela Fundação de Amparo à Pesquisa do Estado de São Paulo (FAPESP) sob o processo 2020/02891-3.

CREDITS: This presentation template was created by **Slidesgo**, including icons by **Flaticon**, and infographics & images by **Freepik**